
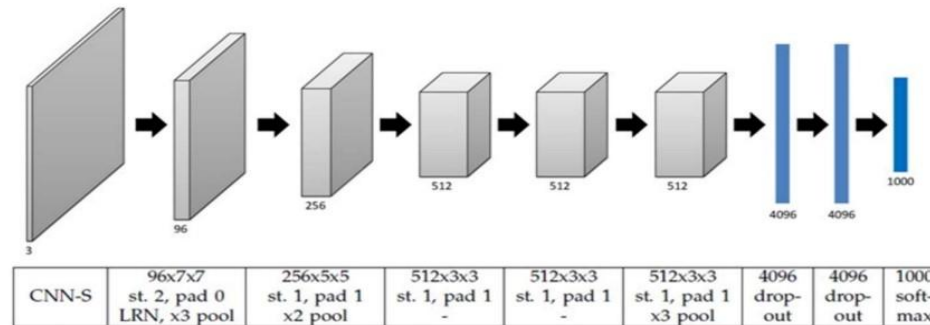


10차 일석이조 조별보고서	
작성일 : 2023년 11월 7일	작성자 : 이학빈
조 모임 일시 : 11월 7일	모임 장소 : 구글미트
참석자 : 이준용, 유정훈, 김동규, 이학빈, 탁성재	조원 : 이준용, 유정훈, 김동규, 이학빈, 탁성재
구 분	내 용
학습 범위와 내용	<p>4.5.1. 생성 모델이란?</p> <p>4.5.2. GAN</p>
<p>질문 내용</p> <p>(모임 전 공지된 개별 학습 범위에서 이해된 것과 못한 것)</p>	<p>Q(1)</p> <p>GAN의 학습은 생성자와 분류자가 서로 경쟁하며 학습하는 모델입니다. 생성자나 분류자 둘 중 하나가 성능이 특히 뛰어난 경우에도 학습이 잘 되는지 또한 학습이 잘 되지 않는다면 이를 해결할 방법이 무엇인지 궁금합니다.</p> <p>A(1)</p> <p>생성자나 분류자 둘 중 하나가 성능이 특히 뛰어나다면, 학습이 제대로 이루어지지 않는다. GAN 의 학습이 잘되기 위해서는 비슷한 수준의 생성자와 분류자가 함께 조금씩 발전해야, 균형 있게 서로 훈련을 주고받기 때문이다. 다시 말해, 두 모델간 실력차가 발생하는 경우에 훈련이 한쪽에 치우쳐 성능이 제약된다.</p> <p>이러한 부분을 해결하기 위해서 나타난 해결책은 바로 DCGAN(Deep Convolutional GAN)이다. DCGAN은 기존 GAN에 존재했던 fully-connected DNN구조를 CNN 구조로 대체한 것으로, 생성자와 분류자의 세부적인 구조가 달라진다.</p>



[기존 fully-connected로 되어있는 GAN의 구조]



Chatfield et al. *Return of the Devil in the Details: Delving Deep into Convolutional Nets*

[fully-connected 구조 대신에 convolution, pooling, padding을 활용한 CNN의 구조]

GAN의 한계를 극복하기 위해 시도된 여러 방법들을 통한 DCGAN의 구조는 아래와 같다.

- Discriminator 에서는 모든 pooling layers 를 strided convolutions 로 바꾸고, Generator 에서는 pooling layers 를 fractional-strided convolutions 으로 바꾼다.
- Generator 와 Discriminator 에 batch-normalization 을 사용한다. 논문에서는 이를 통해 deep generators 의 초기 실패를 막는다고 하였다. 그러나 모든 layer 에 다 적용하면 sample oscillation 과 model instability 의 문제가 발생하여 Generator output layer 와 Discriminator input layer 에는 적용하지 않았다고 한다.

- Fully-connected hidden layers 를 삭제한다.
- Generator 에서 모든 활성화 함수를 Relu 를 쓰되, 마지막 결과에서만 Tanh 를 사용한다.
- Discriminator 에서는 모든 활성화 함수를 LeakyRelu 를 쓴다.

Q(2)

생성모델의 작동 방식에 대해서 알아보았습니다.

A(2)

생성 모델은 크게 지도적 생성모델, 비지도적 생성모델로 이루어져 있습니다.

1. 지도적 생성모델

선형판별분석법(LDA), 이차판별 분석법(QDA)

- $P(x|y=k)$ 의 경우가 특정 확률분포 모형을 따른다고 가정했을때, 해당 k 사건이 가지는 학습데이터들을 이용해 해당 케이스의 통계값을 구함.
- 해당 통계값은 $P(x|y=k)$ 의 사건에 대한 확률 밀도 함수를 나타내며, k의 학습데이터를 어느정도 충족하는 케이스는 높은 확률로 k 사건이라고 예측할 수 있음

2. 비지도적 생성 모델

- 통계적 생성모델
 - 관측된 데이터 모델들의 분포에 따라 원 변수의 확률분포 추정

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

- 각 케이스와 평균치 사이의 오류값의 평균을 구해 확률분포를 추정하게 됨
 - 딥러닝을 활용한 생성모델
 - 많은 데이터를 활용해 생성 모델을 추측함
 - Tractable Density
 - 체인 룰(근처 데이터와 현재 데이터가 유사하다고 가정)을 활용해 케이스 생성함

$$p(x) = \prod_{i=1}^n p(x_i | x_1, \dots, x_{i-1})$$

↑ Likelihood of image x
↑ Probability of i^{th} pixel value given all previous pixels

- Approximate Density
 - 원래 데이터를 압축했다가 복원하면서 조금씩 변형을 가함



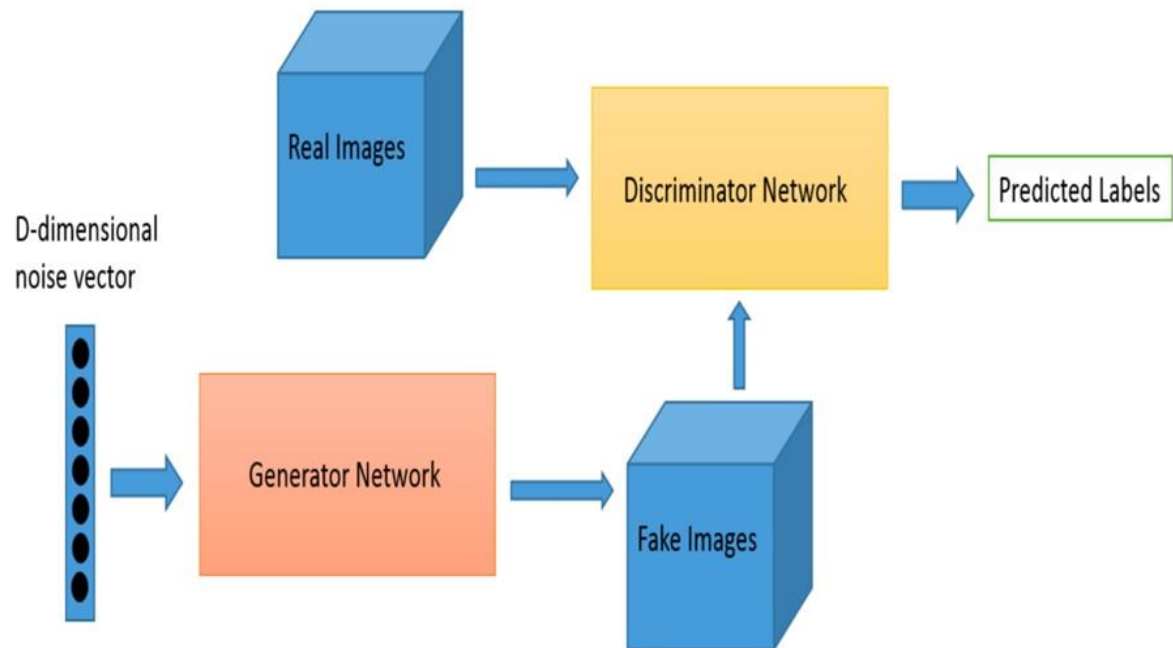
- Implicit Density
- GAN이 포함되는 케이스로서 판별기와 생성기가 서로 영향을 주고받으며 어느 지점까지 서로 수렴시킴

Q(3)

GAN에 대해 더 자세한 내용을 팀원들과 의논해보았습니다.

A(3)

GAN은 Generator(G, 생성모델/생성기)와 Discriminator(D, 판별모델/판별기)라는 서로 다른 2개의 네트워크 이루어져 있으며 이 두 네트워크를 적대적으로 학습시키며 목적을 달성합니다. 생성모델(G)의 목적은 진짜 분포에 가까운 가짜분포를 생성하는 것이고 판별모델(D)의 목적은 표본이 가짜분포에 속하는지 진짜분포에 속하는지를 결정하는 것입니다. 이 2가지 모델을 포함한 GAN의 궁극적인 목적은 "실제 데이터의 분포"에 가까운 데이터를 생성하는 것이며, 따라서 판별기가 진짜인지 가짜인지를 한 쪽으로 판단하지 못하는 경계 (가짜와 진짜를 0과 1로 보았을 때 0.5의 값)에서 가짜 샘플과 실제 샘플을 구별할 수 없는 최적 솔루션으로 간주하게 됩니다.



생성기(G)는 실제 데이터와 비슷한 데이터를 만들어내도록 학습되며, 판별기(D)는 실제 데이터와 G가 생성한 가짜 데이터를 구별하도록 학습됩니다. GAN의 목적함수는 다음과 같은데, 이는 게임이론 타입의 목적함수로 G와 D 2명의 플레이어가 싸우면서 서로 균형점(nash equilibrium)을 찾아가도록 하는 방식입니다.

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

여기서 $V(D, G)$ 의 값은 확률값으로 도출되는데, 이 수식을 각각 D와 G의 관점에서 살펴보면 다음과 같습니다.

먼저 D의 관점에서 실제 데이터(x)를 입력하면 $D(x)$ 가 커지면서 log값이 커지면서 높은 확률값이 나오도록 하고, 가짜 데이터($G(z)$)를 입력하면 log값이 작아짐에 따라 낮은 확률값이 나오도록 학습됩니다. 다시 말해 D는 실제 데이터와 G가 만든 가짜 데이터를 잘 구분하도록 조금씩 업데이트되는 것입니다.

G에서는 Zero-Mean Gaussian 분포에서 노이즈 z 를 멀티레이어 퍼셉트론에 통과시켜 샘플들을 생성하며 이 생성된 가짜 데이터 $G(z)$ 를 D에 input으로 넣었을 때 실제 데이터처럼 확률이 높게 나오도록 학습됩니다. 즉 $D(G(z))$ 값을 높도록, 그리고 전체 확률 값이 낮아지도록 하는 것이며 이는 다시 말해 G가 'D가 잘 구분하지 못하는' 데이터를 생성하도록 조금씩 업데이트되는 것입니다.

실제 학습을 진행할 때는 G와 D 두 네트워크를 동시에 학습시키지 않고 하나의 네트워크를 고정한 상태에서 다른 한 네트워크를 업데이트하는 방식으로 따로따로 업데이트합니다.

Q(4)

GAN을 사용하여 이미지 생성을 수행할 때, 생성자 신경망이 어떻게 무작위한 노이즈를 입력으로 받고 현실적인 이미지를 생성하는지 알아보았다.

A(4)

GAN을 사용하여 이미지를 생성할 때, 생성자 신경망은 무작위한 노이즈 벡터를 입력으로 받고 이를 기반으로 현실적인 이미지를 생성한다. 이 과정은 다음과 같이 동작한다:

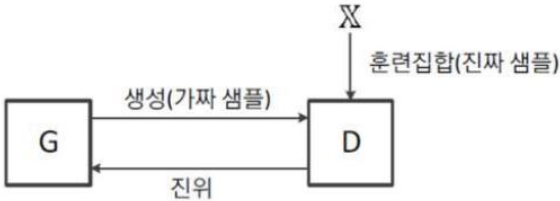
	<p>1. 노이즈 입력: 생성자 신경망은 일반적으로 고정된 크기의 노이즈 벡터(랜덤한 숫자들로 구성)를 입력으로 받는다. 이 노이즈 벡터는 초기에는 완전히 무작위하며, 생성자는 이 노이즈를 현실적인 이미지로 변환해야 한다.</p> <p>2. 노이즈를 이미지로 변환: 생성자는 이 노이즈 벡터를 특정한 방식으로 처리하여 이미지를 생성한다. 이 과정은 신경망 내에서 여러 계층 및 연산을 통해 이루어진다. 생성자의 목표는 노이즈를 입력으로 받아 실제 이미지와 비슷한 특성을 갖는 가짜 이미지를 생성하는 것이다.</p> <p>3. 학습과 업데이트: 생성자는 판별자 신경망이 생성한 이미지를 실제 이미지와 구분하기 어렵게 만들기 위해 훈련된다. 생성자의 손실 함수는 생성된 이미지가 판별자에 의해 "진짜"로 분류되는 것을 목표로 한다. 따라서 생성자는 점차적으로 더 현실적인 이미지를 생성하도록 학습된다.</p> <p>4. 반복적인 훈련: 생성자는 반복적으로 노이즈를 이미지로 변환하고 훈련을 통해 개선한다. 이 과정은 생성자가 점차 더 현실적인 이미지를 생성하도록 하는데 중요하다. 또한 판별자도 함께 훈련되며, 이 경쟁적인 훈련 과정에서 생성자는 판별자를 속이기 위해 계속 발전한다.</p> <p>결과적으로, 생성자 신경망은 무작위한 노이즈를 입력으로 받아 판별자를 속이기 위해 이미지를 생성하는 능력을 키우게 된다. 이것은 고차원 공간에서 노이즈를 낮은 차원의 현실적인 이미지로 변환하는 생성 과정으로 이루어진다.</p> <p>Q(5) GAN 방식의 단점은 무엇인지 궁금합니다.</p> <p>A(5) 1. GAN은 종종 훈련 중 모드 붕괴 현상이 발생할 수 있습니다. 모드 붕괴란 생성자가 다양한 출력을 생성하는 대신, 한 또는 몇몇 모드에만 집중하는 현상을 의미합니다. 이로 인해 다양성이 부족한 결과물을 생성할 수 있습니다.</p>
--	--

	<p>2. GAN 모델의 훈련은 수렴하기 어려울 수 있으며, 고정된 학습률 및 하이퍼파라미터 설정에 민감합니다. 불안정한 훈련 중에 그래디언트 폭주 및 소실 문제가 발생할 수 있습니다.</p> <p>3. GAN의 성능 평가 및 적절한 모델 선택은 도전적입니다. 생성된 결과물의 품질을 정량적으로 측정하거나 여러 모델 중에서 최상의 모델을 선택하는 것은 주관적이고 어려운 과제입니다.</p> <p>4. GAN 모델을 훈련시키려면 종종 대량의 데이터가 필요합니다. 데이터가 부족하면 모델이 과적합되거나 일반화 능력이 제한될 수 있습니다.</p> <p>5. 대규모 GAN 모델을 훈련시키려면 고성능의 그래픽 처리 장치(GPU 또는 TPU)가 필요하며, 이로 인해 하드웨어 비용이 증가할 수 있으며, 많은 계산 리소스와 시간이 필요합니다. 특히, 대규모 모델의 훈련은 여러 일 또는 주를 소요할 수 있으며, 이는 비용과 시간적인 측면에서 제한적일 수 있습니다.</p>
질문내용	<p>Q1.</p> <p>GAN의 최종 목적은 분류 모델이 최종적으로 정확한 분류를 하지 못할 정도의 생성 모델 성능을 내는 것인데, GAN 과정에서 분류 모델의 성능 향상과정은 없나요?</p> <p>분류기의 성능이 생성 모델의 성능 향상보다 더 뛰어나더라도, GAN은 분별기의 목적함수 값이 1/2가 될때까지 학습하게 된다고 알고 있다. 맞는건인가요?</p> <p>Q2.</p> <p>생성 모델은 테이블 정보 없이 사용될 수 있다고 하셨는데 그 이유가 궁금합니다.</p>

조 운영 지침

1. 회의 일정: 조별 회의는 매주 화요일 오후 3 시에 진행되며, 대면으로 약 1 시간 동안 진행된다.
2. 지각 및 결석에 대한 규정: 지각 또는 결석을 누적 2 회 할 경우, 해당 조원은 기프티콘(아메리카노)을 나머지 조원들에게 제공해야 한다.
3. 보고서 제출 방법: 개별 보고서는 조별 회의 시작 1 시간 전까지 카카오톡 단체 톡방에 공유하도록 한다.
4. 조장 선출 및 순서: 조장은 매주 변경되며, 다음과 같은 순서로 선정됩니다. 탁성재 학우 -> 이준용 학우 -> 유정훈 학우 -> 김동규 학우 -> 이학빈 학우
5. 본 운영 지침은 모든 조원이 공동으로 합의한 사항으로, 조원 간의 원활한 소통과 협력을 위해 준수할 필요가 있다.
6. 조별 모임에 참석하지 않는다든지 보고서를 작성하지 않는다든지 혹은 지각 등의 조의 단합을 저해하는 조원은 조원들 스스로 학기 초에 정한
규정에 의하여 처리할 수 있다. (벌금 부과나 조 퇴출 등) 이러한 규정들은 조가 결정된 후에 서로 조별로 협의하여 규정을 만들어 제출하며 규정은 계속 개정할 수도 있다. (규정을 소급적용할 수는 없다.)
7. 조별모임을 원하지 않는 사람이나 퇴출된 학생은 다른 조에 동의를 얻어서 합류하거나 보고서 작업을 혼자 진행한다. (조원의 최대 숫자는 학기 초에 정해진다.)
8. 개인 보고서와 조별 보고서 모두 "자료조사 " 혹은 교재 내용을 요약 정리하는 것에 중점이 있는 것이 아니라 자신이 혹은 조원들이 잘 모르겠는 것들 이해되지 않는 것들이 무엇인지를 파악하는 데 중점을 둔다.9. 개인 보고서와 조별 보고서 모두 "자료조사" 혹은 교재 내용을 요약 정리하는 것에 중점이 있는 것이 아니라 자신이 혹은 조원들이 잘 모르겠는 것들 이해되지 않는 것들이 무엇인지를 파악하는 데 중점을 둔다.
9. 작성된 조별 보고서는 수업시간 혹은 과목 홈페이지 게시판을 통하여 설명될 것이다.

개별 레포트

학과	컴퓨터 전자시스템 공학	학번	201904458	이름	이준용
구분	내용				
학습 범위	기계학습 4장 4.5 생성모델 4.6 딥러닝은 왜 강력한가				
학습 내용	<div> 4.5 생성모델 <ul style="list-style-type: none"> ● 분별모델은 학습단계에서 수식으로 표현하면 $P(y x)$로 추정한다. 예측단계에서는 $f:x \rightarrow y$ 이고 지도학습이다. ● 생성모델은 학습단계에서 수식으로 표현하면 $P(x)$또는 $P(x y)$또는 $P(x,y)$으로 추정된다. 예측단계에서는 $x \rightarrow y$, $y \rightarrow x$, $f \rightarrow x, y$ 으로 나타낼 수 있고 비지도 학습이다. ● 실제 상황에서 생성모델은 현대 기계 학습은 주로 딥러닝 모델을 사용하여 확률 분포를 암시적으로 표현한다. GAN(generative adversarial network), VAE(variational autoencoder), RNN 등등 ● GAN 의 아이디어 = 생성기 G(가짜 샘플) 분별기 D(진위구별)의 대립 구도, 결국 가짜가 진짜처럼 보이게 할수록 성능이 뛰어나다. 최종 목표는 G 가 만들어내는 샘플을 D 가 구별하지 못하는 수준까지의 학습이다. <div style="text-align: center;">  <p>그림 4-34 GAN의 원리</p> </div> <ul style="list-style-type: none"> ● 개선된 GAN 은 특징 매칭, 가상 배치 정규화, 미니배치 분별 등 기법 적용. $P(x)$대신 $P(x,y)$을 추정하여 레이블이있는 샘플을 생성->준지도 학습에 활용한다. DCGAN 은 DMLP 대신 CNN 을 사용한다. CNN 과 데이터 흐름이 반대이다. <div> GAN의 목적함수 목적함수 J_D, J_G로 로그우도를 사용 </div> </div>				

	<div> <div> 분별기 D의 목적함수 J_D $\hat{\theta}_D = \operatorname{argmax}_{\theta_D} J_D(\theta_D)$ 이때 $J_D(\theta_D) = \log(f_D(\mathbf{x}^{\text{real}})) + \log(1 - f_D(\mathbf{x}^{\text{fake}}))$ $= \log(f_D(\mathbf{x}^{\text{real}})) + \log(1 - f_D(f_G(\mathbf{z})))$ </div> <div> 생성기 G의 목적함수 J_G $\hat{\theta}_G = \operatorname{argmin}_{\theta_G} J_G(\theta_G)$ 이때 $J_G(\theta_G) = \log(1 - f_D(f_G(\mathbf{z})))$ </div> </div> <p>J_D와 J_G가 서로 상반관계에 있으므로, 결과는 1/2로 수렴한다.</p> <p>4.6 딥러닝은 왜 강력한가</p> <p>고전적인 방법에서는 분할, 특징 추출, 분류를 따로 구현한 다음 이어 붙였으며, 각 과정이 사람의 직관에 의존하므로 성능이 떨어지며, 인식 대상마다 새로 설계해야 했음.</p> <p>고전적인 방법의 경우 특징공간에 문제가 생기면 문제점을 대상으로 fine tuning을 하면 되지만, 딥 러닝은 전체를 재학습 시켜야 하는 단점도 있음</p> <p>(데이터 양이 적은 경우에도 분류 모델을 만들 수 있다는 장점이 있음)</p> <p>딥 러닝은 전체 과정을 동시에 최적화 함 (end to end learning)</p> <p>깊은 신경망에서는 각 층의 역할이 잘 구분되나, 얇은 신경망은 한 층이 여러 형태의 특징을 모두 담당함</p> <p>딥 러닝의 앞 부분(저급 특징을 추출하는 부분)은 다른 분류에서도 활용할 수 있음(Transfer learning)</p> <p>은닉층의 깊이가 깊을수록 표현력이 좋으며, 성능이 좋음.</p>
--	---

개별 레포트

학과	컴퓨터전자시스템 공학과	학번	201800615	이름	김동규
구분	내용				
학습 범위	기계학습 4장 4.5 생성 모델 4.6 딥러닝은 왜 강력한가?				
학습 내용	4.5 생성 모델 - 분별모델 - 주어진 케이스(y)가 특정한 사건(x)일 확률을 추정함 - 학습단계				

- 어떤 사건(x)이 있을때 케이스 (y)일 확률 추정 (P(Y|X))
- 예측 단계
 - 어떤 확률이 주어졌을 때, 발생할 수 있는 케이스 예측

- GAN

- 분별기와 생성기를 페어로 맺어 서로 구별할 수 없을때까지 분별과 생성 반복
- 분별기는 직접 집어넣는 훈련집합(진짜)과 생성된 집합(가짜)를 구별함
- 생성기는 분별기에서 분류한 진위여부를 가지고 계속 가짜 집합을 생성함




그림 4-34 GAN의 원리

- GAN의 목적함수

- 분별기의 목적함수와 생성기의 목적함수를 활용
- 분별기의 목적함수 = 케이스 x가 진짜일 확률, 가짜일 확률을 해당 식에 적용해 계산함

$$\hat{\theta}_D = \operatorname{argmax}_{\theta_D} J_D(\theta_D)$$

$$\begin{aligned} \text{이때 } J_D(\theta_D) &= \log(f_D(\mathbf{x}^{\text{real}})) + \log(1 - f_D(\mathbf{x}^{\text{fake}})) \\ &= \log(f_D(\mathbf{x}^{\text{real}})) + \log(1 - f_D(f_G(\mathbf{z}))) \end{aligned}$$

- 생성기의 목적함수

$$\hat{\theta}_G = \operatorname{argmin}_{\theta_G} J_G(\theta_G)$$

$$\text{이때 } J_G(\theta_G) = \log(1 - f_D(f_G(\mathbf{z})))$$

4.6 딥러닝은 왜 강력한가?

- 초기의 기계학습은 분할, 특징 추출, 분류를 모두 따로 구한 후, 나중에 합치는 방식으로 진행됨.
- 사용되는 기법은 인간의 직관에 의해 정해짐
- 하나의 목적을 위해 만들어진 기법은 다른 목적에 적용 불가함
- 은닉층의 갯수를 조정함으로써 정교하게 케이스를 분할 가능함.
- 입력층과 가까운 은닉층(특징 추출)을 다른 케이스에서 사용 가능함

개별 레포트

학과	철학과	학번	201802344	이름	유정훈
구분	내용				
학습 범위	기계학습 4장 4.5 생성모델 4.6 딥러닝은 왜 강력한가				
학습 내용	<p><생성모델이란></p> <p>: 생성모델은 주어진 학습 데이터를 학습하고 학습 데이터의 분포를 따르는 유사 데이터를 생성하는 모델이다.</p> <p>: 분류모델은 지도학습을 기반으로 학습단계에서 데이터 x가 주어졌을 때의 LABEL Y가 이루는 확률분포 $P(Y X)$를 도출해낸다.</p> <p><개선된 GAN></p> <p>: 특징 매칭, 가상 배치 정규화, 미니배치 분별 등 기법을 적용시켰다.</p> <p>: $P(x)$ 대신 $P(x,y)$를 추정하여 레이블이 있는 샘플을 생성한다.</p> <p><딥러닝은 왜 강력한가?></p> <ol style="list-style-type: none"> 전체 과정을 동시에 최적화 <p>: 고전적인 방법에서는 분할, 특징 추출, 분류를 따로 구현한 다음 이어 붙였다.</p> <p>: 사람의 직관에 따르므로 성능의 한계가 있다. 인식 대상이 달라지면 새로 설계해야 한다.</p> <p>: 딥러닝은 전체 과정을 동시에 최적화시킨다.</p> 깊이의 중요성 <p>: 점선은 20개 노드를 가진 은닉층 하나짜리 신경망이다.</p> <p>: 실선은 각각 10개 노드를 가진 은닉층 두 개짜리 신경망이다. 따라서 더 정교하게 분할할 수 있다.</p> 계층적 특징 <p>: 깊은 신경망에서는 층의 역할이 잘 구분되지만 얇은 신경망은 하나 또는 두개의 은닉층이 여러 형태의 특징을 모두 담당한다.</p> 				

개별 레포트

학과	컴퓨터 전자시스템 공학	학번	201702899	이름	이학빈
----	-----------------	----	-----------	----	-----

구분	내용
학습 범위	<p>기계학습 4장</p> <p>4.5 생성모델</p> <p>4.6 딥러닝은 왜 강력한가</p>
학습 내용	<p>생성 모델이란 무엇인가?</p> <p>생성 모델(Generative Model)은 확률적인 방식으로 데이터를 생성하는 모델로, 주어진 데이터 분포에서 실제 데이터와 유사한 새로운 데이터를 생성할 수 있는 모델입니다. 확률적 모델링의 한 형태로, 다양한 응용 분야에서 활용됩니다. 생성 모델은 데이터 생성, 이미지, 음성 및 텍스트 생성, 데이터 보강, 안전한 데이터 공유 등 다양한 작업에 사용됩니다.</p> <p>GAN이란 무엇인가?</p> <p>GAN은 Generative Adversarial Network의 약자로, 생성적 적대 신경망(Generative Adversarial Network)의 약자입니다. 생성 모델을 학습하는 데 사용되는 딥러닝 기술 중 하나이며 두 개의 신경망, 생성자(Generator)와 판별자(Discriminator)로 구성되며, 이 두 신경망은 서로 대립하는 역할을 수행합니다.</p> <p>생성자(Generator):</p> <p>생성자는 주어진 랜덤 노이즈 벡터를 입력으로 받아, 실제 데이터와 유사한 가짜 데이터를 생성합니다. 초기에는 랜덤한 가중치와 편향을 사용하여 무작위로 데이터를 생성하고, 훈련 과정 동안 이 가중치와 편향을 조정하여 점점 실제 데이터와 더 유사한 데이터를 생성할 수 있도록 학습합니다.</p> <p>판별자(Discriminator):</p> <p>생성자가 생성한 가짜 데이터와 실제 데이터를 구별하는 역할을 합니다. 입력으로 실제 데이터와 가짜 데이터를 받아, 각각 어느 것이 진짜인지 판별합니다. 훈련 과정 동안 판별자는 실제 데이터와 가짜 데이터를 올바르게 분류할 수 있도록 학습합니다.</p> <p>GAN의 핵심 아이디어는 생성자와 판별자가 서로 경쟁하며 발전하도록 하는 것입니다. 생성자는 판별자를 속이기 위해 더 실제 데이터와 유사한 가짜 데이터를 생성하려고 노력하고, 판별자는 더 효과적으로 가짜 데이터와 실제 데이터를 구분하려고 노력합니다. 이 경쟁은 두 신경망 모두 성능을 향상시키게 하며, 결과적으로 생성자는 실제 데이터와 거의 구분할 수 없는 고품질 가짜 데이터를 생성하게 됩니다.</p> <p>GAN은 이미지 생성, 음악 생성, 텍스트 생성 등 다양한 응용 분야에서 사용됩니다. 또한, GAN의 변형과 확장도 많이 개발되어 실제 세계 문제를 해결하기 위한 다양한 응용이 가능합니다.</p> <p>딥러닝은 왜 강력한가?</p>

	<ol style="list-style-type: none"> 1. 딥러닝 모델은 여러 개의 은닉층을 가진 다층 신경망으로 구성됩니다. 이 다층 구조를 통해 모델은 복잡한 비선형 관계를 학습할 수 있으며, 고차원 데이터를 다루기에 적합합니다. (다층 신경망 아키텍처) 2. 대규모 데이터셋에서 훈련되어 이로 인해 모델은 실제 세계의 다양한 패턴을 학습하고 일반화 능력을 향상시킵니다. (대규모 데이터 학습) 3. 특성 추출 단계를 자동화하며, 데이터로부터 의미 있는 특성을 추출하는 과정을 모델이 스스로 수행합니다. 이로써 특성 공학의 수고를 덜 수 있습니다. 4. 사전 훈련된 모델을 사용하여 새로운 작업에 적용하는 전이 학습 기술을 제공합니다. 이를 통해 적은 양의 데이터로도 강력한 모델을 구축할 수 있으며, 훈련 시간과 비용을 절약할 수 있습니다. (전이 학습) 5. 딥러닝 모델은 모델의 크기와 복잡성을 조절하여 다양한 요구 사항에 맞출 수 있으며, 병렬 처리를 통해 대규모 데이터를 효과적으로 처리할 수 있습니다. (확장성) 6. 이미지, 음성, 텍스트 및 구조화된 데이터와 같은 다양한 데이터 유형을 처리할 수 있으며, 이러한 데이터 유형을 결합하여 더 풍부한 정보를 얻을 수 있습니다. (다양한 데이터 유형 처리) 7. 경사 하강법과 같은 최적화 알고리즘을 사용하여 모델 파라미터를 조정하여 손실을 최소화합니다. 이러한 최적화 기술을 통해 모델을 효과적으로 학습할 수 있습니다. (확률적 경사 하강법) <p>딥러닝 분야는 지속적인 연구와 혁신이 이루어지며, 새로운 아이디어와 기술이 빠르게 발전하고 적용되고 있습니다.</p>
--	--